




Ética Práctica para Ciencia de Datos

Hola, soy Luciana



Soy investigadora en CONICET y profesora en FAMAF, donde investigo sobre evaluación de errores y sesgos sociales de modelos generativos multimodales.

También soy directiva de Khipu (Latinoamericanos en Machine Learning) y miembro ejecutivo de NAACL (Asociación de Lingüística Computacional de las Americas)

Foto tomada en la Cumbre de AI Safety, Inglaterra, Nov 2023

Protección de Datos Personales: Ley 25.326

La Ley 25.326, sancionada el 4 de octubre de 2000, establece un marco legal para la protección de los datos personales en **Argentina**. Esta ley define los conceptos clave relacionados con la información personal, incluyendo los datos sensibles, y establece los derechos de los titulares de los datos, así como las obligaciones de quienes los tratan.

Caso: Brasil, AirBnB



Definiciones Clave

La ley define "datos personales" como cualquier información relacionada con personas físicas o de existencia ideal, ya sean determinadas o determinables. Los "datos sensibles" son aquellos que revelan información delicada como el origen racial, opiniones políticas o la salud.

Datos Personales

Información sobre personas físicas o de existencia ideal, ya sean determinadas o determinables.

Datos Sensibles

Datos personales que revelan información delicada como el origen racial, opiniones políticas o la salud. (lo vemos en otro slide)

Titular de los Datos

Persona cuyos datos son objeto del tratamiento al que se refiere la ley.

Disociación de Datos

Tratamiento de datos personales de manera que la información obtenida no pueda asociarse a una persona determinada.



Principios del Tratamiento de Datos

La ley establece principios fundamentales para el tratamiento de datos personales, asegurando que la información se maneje de manera responsable y ética. Estos principios incluyen la certeza, la pertinencia, la no excesividad y la actualización de los datos.

1 Certeza

Los datos recolectados deben ser ciertos y veraces.

2 Adecuación y Pertinencia

Los datos deben ser adecuados y pertinentes al ámbito y finalidad para los que se obtuvieron.

3 No Excesividad

Los datos no deben ser excesivos en relación con el ámbito y finalidad para los que se obtuvieron.

4 Actualización

Los datos deben ser exactos y actualizarse cuando sea necesario.



Finalidades del Tratamiento

La ley prohíbe el uso de datos personales para finalidades distintas o incompatibles con aquellas que motivaron su obtención. Esto significa que la información solo puede utilizarse para los propósitos para los que fue recopilada inicialmente.

1

Obtención

Los datos se recopilan para un propósito específico comunicado en el **consentimiento informado**.

2

Tratamiento

Los datos se procesan y almacenan de acuerdo con la finalidad inicial.

3

Uso

Los datos se utilizan **únicamente para la finalidad** para la que fueron recolectados. A menos que estén en el dominio público por licencia.

ACLARAR AYER

Consentimiento Informado

El tratamiento de datos personales es ilícito si el titular no ha dado su consentimiento libre, expreso e informado. Este consentimiento debe constar por escrito o por otro medio que permita su equiparación.

Consentimiento

El titular de los datos debe dar su consentimiento libre, expreso e informado.

Excepciones

No se requiere consentimiento en casos como la **obtención de datos de fuentes públicas** (pero hay que ver licencias

<https://www.dataprovenance.org/>)

.

Información

Se debe informar al titular sobre la finalidad del tratamiento, los destinatarios de los datos y sus derechos.

Categoría de Datos Sensibles

La ley establece que ninguna persona puede ser obligada a proporcionar datos sensibles, como aquellos que revelan origen racial, opiniones políticas o información sobre la salud.

Datos Sensibles	Ejemplos
Origen racial y étnico	Raza, origen étnico
Opiniones políticas	Afiliación política, creencias políticas
Convicciones religiosas	Religión, creencias religiosas
Información sobre la salud	Condiciones médicas, historial médico
Vida sexual	Orientación sexual, prácticas sexuales

Seguridad y Confidencialidad

El responsable del archivo de datos debe adoptar medidas técnicas y organizativas para garantizar la seguridad y confidencialidad de los datos personales. Esto incluye evitar la adulteración, pérdida, consulta o tratamiento no autorizado de la información.



Seguridad

Medidas técnicas y organizativas para proteger los datos de accesos no autorizados.



Confidencialidad

Mantener la información privada y evitar su divulgación no autorizada.



Integridad

Garantizar la exactitud y la integridad de los datos.



Disponibilidad


Asegurar el acceso a los datos cuando sea necesario.





Deber de Confidencialidad

El responsable y las personas que intervengan en el tratamiento de datos personales están obligados al secreto profesional respecto de los mismos. Esta obligación subsiste incluso después de finalizada su relación con el titular del archivo de datos.



Derecho de Acceso, Rectificación y Supresión

El titular de los datos tiene derecho a solicitar y obtener información sobre sus datos personales incluidos en bancos de datos públicos o privados. También tiene derecho a que sean rectificados, actualizados y, cuando corresponda, suprimidos o sometidos a confidencialidad los datos personales de los que sea titular.



Derecho de Acceso

Solicitar y obtener información sobre sus datos personales.



Derecho de Rectificación

Solicitar la corrección de datos inexactos o incompletos.



Derecho de Supresión

Solicitar la eliminación de datos personales cuando corresponda.

LEGAL ≠ ÉTICO



Association for
Computing Machinery

Advancing Computing as a Science & Profession

The Code

ACM Code of Ethics and Professional Conduct

Affirming our obligation to use our skills to benefit society

<https://www.acm.org/binaries/content/assets/about/acm-code-of-ethics-booklet.pdf>

1 | General Ethical Principles

A computing professional should...

1.1

Contribute to society and to human well-being, acknowledging that all people are stakeholders in computing.

This principle, which concerns the quality of life of all people, affirms an obligation of computing professionals, both individually and collectively, to use their skills for the benefit of society, its members, and the environment surrounding them. This obligation includes promoting fundamental human rights and protecting each individual's right to autonomy. An essential aim of computing professionals is to minimize negative consequences of computing, including threats to health, safety, personal security, and privacy. When the interests of multiple groups conflict, the needs of those less advantaged should be given increased attention and priority.

Computing professionals should consider whether the results of their efforts will respect diversity, will be used in socially responsible ways, will meet social needs, and will be broadly accessible. They are encouraged to actively contribute to society by engaging in pro bono or volunteer work that benefits the public good.

In addition to a safe social environment, human well-being requires a safe natural environment. Therefore, computing professionals should promote environmental sustainability both locally and globally.

All people are stakeholders in computing.

1.2

Avoid harm.

In this document, "harm" means negative consequences, especially when those consequences are significant and unjust. Examples of harm include unjustified physical or mental injury, unjustified destruction or disclosure of information, and unjustified damage to property, reputation, and the environment. This list is not exhaustive.

Well-intended actions, including those that accomplish assigned duties, may lead to harm. When that harm is unintended, those responsible are obliged to undo or mitigate the harm as much as possible. Avoiding harm begins with careful

1.3

Be honest and trustworthy.

Honesty is an essential component of trustworthiness. A computing professional should be transparent and provide full disclosure of all pertinent system capabilities, limitations, and potential problems to the appropriate parties. Making deliberately false or misleading claims, fabricating or falsifying data, offering or accepting bribes, and other dishonest conduct are violations of the Code.

Computing professionals should be honest about their qualifications, and about any limitations in their competence to complete a task. Computing professionals should be forthright about any circumstances that might lead to either real or perceived conflicts of interest or otherwise tend to undermine the independence of their judgment. Furthermore, commitments should be honored.

Computing professionals should not misrepresent an organization's policies or procedures, and should not speak on behalf of an organization unless authorized to do so.

Honesty is
an essential
component
of trust.

1.4

Be fair and take action not to discriminate.


The values of equality, tolerance, respect for others, and justice govern this principle. Fairness requires that even careful decision processes provide some avenue for redress of grievances.

Computing professionals should foster fair participation of all people, including those of underrepresented groups. Prejudicial discrimination on the basis of age, color, disability, ethnicity, family status, gender identity, labor union membership, military status, nationality, race, religion or belief, sex, sexual orientation, or any other inappropriate factor is an explicit violation of the Code. Harassment, including sexual harassment, bullying, and other abuses of power and authority, is a form of discrimination that, amongst other harms, limits fair access to the virtual and physical spaces where such harassment takes place.

The use of information and technology may cause new, or enhance existing, inequities. Technologies and practices should be as inclusive and accessible as possible and computing professionals should take action to avoid creating systems or technologies that disenfranchise or oppress people. Failure to design for inclusiveness and accessibility may constitute unfair discrimination.

Preguntas fundamentales

El dilema del pollito




pollo



gallina



El dilema del pollito



pollo




gallina






Ético?

El dilema del pollito



- Existen zonas grises. A menudo no tenemos respuestas fáciles.
- La ética puede cambiar con el tiempo junto con los valores y creencias de las personas.
- Legal $\neq$ Ético

El dilema del IQ



- **I**ntelligence **Q**uotient: un número usado para expresar la aparente inteligencia relativa de una persona


El dilema del IQ

Podemos intentar entrenar un clasificador para predecir el CI a partir de fotos y textos. Discutamos si es ético construir esa tecnología y cuáles son los riesgos..

- Quién se beneficiaría?
- Quién podría sufrir daños? Se puede usar de forma incorrecta?
- Cuáles son los riesgos de una solución?

Estas preguntas nos ayudan a ser conscientes del impacto de nuestro trabajo sobre la gente

“AI Gaydar”, 2017



“Al Gaydar”

- Pregunta a realizar a los datos
 - Identificar la orientación sexual según los rasgos de la cara
- Datos
 - Fotos bajadas de una aplicación tipo Tinder
 - 35,326 fotos de 14,776 personas, blancas, homosexuales y heterosexuales, hombres, mujeres.
- Métodos
 - Un modelo de redes neuronales que usaban características de la cara, del peinado, la presencia de maquillaje, textura aparente de la piel etc, era basado en características
- Precisión
 - 81% para hombres, 74% para mujeres

“AI Gaydar”

- Pregunta a realizar a los datos
 - Identificar la orientación sexual según los rasgos de la cara
- Datos
 - Fotos bajadas de una aplicación tipo Tinder
 - 35,326 fotos de 14,776 personas, blancas, homosexuales y heterosexuales, hombres, mujeres.
- Métodos
 - Un modelo de redes neuronales que usaban características de la cara, del peinado, la presencia de maquillaje, textura aparente de la piel etc, era basado en características
- Precisión
 - 81% para hombres, 74% para mujeres

Qué salió mal?



Trending

Artificial Intelligence as Surrogate Decision-Maker

Opinion | July 22, 2024

Accelerated Chest Pain Treatment With Artificial Intelligence-Informed Triage

Research | July 22, 2024

New Online

Views **6,215** | Citations **1** | Altmetric **79** | Comments **2**

Viewpoint

July 22, 2024

Can Artificial Intelligence Speak for Incapacitated Patients at the End of Life?

Teva D. Brender, MD¹; Alexander K. Smith, MD²; Brian L. Block, MD³

» Author Affiliations | Article Information

JAMA Intern Med. Published online July 22, 2024. doi:10.1001/jamainternmed.2024.2676



Download PDF




Cite This



Permissions



Comment




Qué pasa en las publicaciones científicas de LLMs?

Principios de las ciencias de la salud (**Declaración Helsinki 1964**)


Surgen para las ciencias de la salud, pero se extendieron a muchas otras ciencias, operacionalizan declaración de derechos humanos (ONU, 1948)

- Respeto por las personas / **Autonomía**: las personas tienen derecho a decidir libremente y deben dar su **consentimiento informado**.
- Beneficencia: maximizar **beneficios** y reducir daños.
- No maleficencia: no hacer **daño**, incluso si hay posibles beneficios.
- Justicia: distribuir beneficios y cargas de manera equitativa, evitando la explotación de grupos **vulnerables** (grupos *minorizados*).


Proportion of ACL Papers with ECS by Year




Proportion of Papers with ECS by Event and Year




Percentage papers mentioning 'Who Benefits'



Percentage papers mentioning 'Who Gets Harmed'



Percentage papers mentioning 'Vulnerable Population'



Ética en tiempos de IA y LLMs

Recipe of a generative AI model


1. Scrape as much data as possible

- a. Probably from the Internet (consentimiento?)
- b. You can also do some filtering (privacidad?)



2. Pretrain a language model on this data

- a. The model is trained to predict the next word in a sequence, e.g. “The cat in the ...” (veracidad?)



3. Set the model up to ‘interact’ with humans and keep training it based on their inputs

- a. This is called “Reinforcement Learning from Human Feedback”, if you want to sound fancy (pago?)





Common Crawl


1. Data

- ◎ The main way data is sourced from the Internet is via the **Common Crawl**, which provides “dumps” of text from the Internet every few months
- ◎ These dumps are terabytes of data from the Internet, which can then be used for extracting specific types of content depending on the type of model trained:
 - Raw text for **language models**
 - Images for **computer vision models**
 - Pairs of image URLs and alt-text for **text-to-image models**

1. Data

- ◎ Scraping (text and image) data from the Web raises questions of:
 - **License:** who does Web content belong to? How can we enforce licenses and author rights?
 - **Content:** which websites are “acceptable”? (according to whom?)
 - **Consent:** should we have ‘opt-out’ mechanisms for removing one’s data from training sets? Or ‘opt-in’ to allow our data to be used?
- ◎ Most Web-scraped datasets ignore these issues, but we are starting to see more lawsuits and debate about the legality of data

2. Pretraining




But also:

- Models of increasing complexity without interpretability
- Lack of documentation of models and datasets
- Need for more expensive/specialized hardware to run AI models
- Creation of a divide between those with skills and resources and those who lack this access

Source: [Solaiman \(2023\)](#)

2. Pretraining



Model name	Number of parameters	Datacenter PUE	Carbon intensity of grid used	Power consumption	CO ₂ eq emissions
GPT-3	175B	1.1	429 gCO ₂ eq/kWh	1,287 MWh	502 tonnes
Gopher	280B	1.08	330 gCO ₂ eq/kWh	1,066 MWh	352 tonnes
OPT	175B	1.09 ²	231 gCO ₂ eq/kWh	324 MWh	70 tonnes
BLOOM	176B	1.2	57 gCO ₂ eq/kWh	433 MWh	25 tonnes

We're getting a better idea of AI's true carbon footprint

AI startup Hugging Face has undertaken the tech sector's first attempt to estimate the broader carbon footprint of a large language model.

By Melissa Heikkilä

November 14, 2022



Sources: [HPE \(2021\)](#), [Luccioni et al., 2022](#), [2023](#)

3. Human Interaction

- ◎ Pretrained models are missing the interactive component that makes models like ChatGPT so popular
- ◎ They need to continue to be trained for *thousands of hours* based on human feedback
- ◎ This means that much of the machine ‘intelligence’ is actually explicitly instilled in AI models by humans

PRESENTED BY
BUSINESS • TECHNOLOGY

Exclusive: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic



This image was generated by OpenAI's image-generation software, Dall-E 2. The prompt was: "A seemingly endless view of African workers at desks in front of computer screens in a printmaking style." TIME does not typically use AI-generated art to illustrate its stories, but chose to in this instance in order to draw attention to the power of OpenAI's technology and shed light on the labor that makes it possible. Image generated by Dall-E 2/OpenAI

Source: [TIME Magazine](https://www.time.com/2023/03/14/openai-kenyan-workers-chatgpt-toxicity/)

What can be done?
*(or rather, what is being
done?)*



Data

Data and Consent

Backend url:

<https://knn5.laion>

Index:

laion_5B

french cat



[Clip retrieval](#) works by converting the text query to a CLIP embedding, then using that embedding to query a knn index of clip image embeddings

Display captions ☒

Display full captions ☐

Display similarities ☐

Safe mode ☒

Hide duplicate urls ☒

Hide (near) duplicate images ☒

Search over

image

Search with multilingual clip ☐



french cat



french cat



How to tell if your feline is french. He wears a b...



イケメン猫モデル「トキ・ナンタケット」がかっこいい - NAVER まとめ



Hilarious pics of funny cats! funnycatsgif.com



Hipster cat



網友挑戰「加幾筆畫出最創意貓咪圖片」，笑到岔氣之後我也手



cat in a suit Georgian sells tomatoes




French Bread Cat Loaf Metal Print

[LAION 5B](#)

Artist finds private medical record photos in popular AI training data set

LAION scraped medical photos for AI research use. Who's responsible for taking them down?

BENJ EDWARDS - 9/21/2022, 11:43 AM




Enlarge / Censored medical images found in the LAION-5B data set used to train AI. The black bars and distortion have been added.

[Ars Technica](#)

Understanding and Exploring Data

- Understanding what datasets contain and where they come from is important for understanding the values they carry
- There are toolkits (e.g. what-if) for evaluating dataset contents and helping users investigate anomalies and biases



[MedMCQA dataset](#)

Here is the list of all the duplicated items and their counts in your dataset:

	count	text
0	5	I couldn't could up with another question. But i need to fill this space because I can't submit the hit.
1	5	Who won this season of Idol?
2	5	Which Caribbean nation is in the top quartile of HDI (but missing IHDI)?

[SQuAD - Data Measurements Tool](#)

Es tu turno: Data statements

Ética Práctica para Ciencia de D...

Inicio · Programa · Recursos · **Práctico**



Trabajos prácticos

Práctico: Data Statements

Metodología de documentación de un dataset: contenidos, objetivos y proceso de obtención de datos basado en [Toward Mitigating System Bias and Enabling Better Science](#) y [Datasheets for Datasets](#). [Link](#) a documento modelo (hacer una copia antes de completar). [Link](#) a video guía para hacer el práctico.



Accesso a frameworks



¿Qué tipos de análisis podemos realizar?

Explicabilidad

Dado un **modelo** nos ayuda a **comprender** mejor su comportamiento.

Fairness

Utilizar indicadores de fairness para detectar posibles inequidades en **datos** y **modelos**.



¿Cómo se relacionan estos conceptos?

La gran mayoría de las técnicas de fairness se basan en la existencia de **variables protegidas explícitas**, que suelen ser datos demográficos.

Muchas veces no vamos a contar con esta información pero el modelo podría tener comportamientos poco deseados o injustos de igual manera.



¿Cómo se relacionan estos conceptos?

Poder **entender y explicar** el comportamiento del modelo es fundamental, muchas veces no basta con analizar/optimizar métricas de fairness.

Si entendemos sesgo como “**errores sistemáticos**” entender el comportamiento de nuestro modelo nos ayuda a detectar sesgos.

¿Qué tipos de análisis podemos realizar?

Explicabilidad

Dado un **modelo** nos ayuda a **comprender** mejor su comportamiento.

¿Que queremos entender?


Fairness

Utilizar indicadores de fairness para detectar posibles inequidades en **datos** y **modelos**.

¿Cómo definimos comportamiento injusto?



¡Depende de la aplicación y el contexto de uso!



¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio
- ◎ Minimizar tiempo de escritura de código
- ◎ ¡Debugger de modelos!
- ◎ Poder anticiparnos a comportamiento indeseado
- ◎ Calidad y robustez

¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio
- ◎ Minimizar tiempo de escritura de código
- ◎ ¡Debugger de modelos!
- ◎ Poder anticiparnos a comportamiento indeseado
- ◎ Calidad y robustez

Estas herramientas permiten que un experto de dominio pueda conducir análisis del modelo sin necesidad de saber programar, encontrando errores y facilitando el desarrollo iterativo.

¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio
- ◎ Minimizar tiempo de escritura de código
- ◎ ¡Debugger de modelos!
- ◎ Poder anticiparnos a comportamiento indeseado
- ◎ Calidad y robustez

Si bien hay partes del que se repiten el análisis depende tanto del contexto y los casos de uso que si se escribe código para cada parte del proceso puede volverse muy tedioso, gasta demasiado tiempo y esto dificulta el análisis.

¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio

- ◎ Minimizar tiempo de escritura

- ◎ ¡Debugger de modelos!

- ◎ Poder anticiparnos a comportamientos

- ◎ Calidad y robustez

Estas herramientas permiten acceder a comportamiento interno del modelo en el caso de modelos neuronales. Para todo tipo de modelo nos permiten encontrar casos borde, datos mal etiquetados, mala performance del modelo en grupos particulares, etc

¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio
- ◎ Minimizar tiempo de escritura
- ◎ ¡Debugger de modelos!
- ◎ Poder anticiparnos a comportamiento indeseado
- ◎ Calidad y robustez

Muchos de estos modelos nos permiten agregar datos artificiales de manera sencilla, incluyen procesos de data augmentation, agregan ruido, hacer análisis de ablacion, de causalidad, etc...

¿Porque utilizar frameworks orientados a ética?

- ◎ Inclusión de expertos de dominio

- ◎ Minimizar tiempo de escritura de código

- ◎ ¡Debugger de modelos

- ◎ Poder anticiparnos a

- ◎ Calidad y robustez

En muchos casos las métricas tradicionales no van a ser suficientes como medida de calidad de los modelos.

Es necesario entender en profundidad el comportamiento de los modelos, sobretodo cuando estos impactan en la vida de las personas.

lo


Algunos frameworks para python:



[What-if tool](#): Orientado a **métricas de fairness**, exploración de datos tabulares y **contrafácticos**. Tiene soporte para imágenes y texto. UI interactiva, no hace falta escribir código.



[Fairlearn](#): Métricas de **fairness**, algoritmos de **mitigación**, **visualizaciones**. Recursos educativos y buena documentación, pero requiere mucha escritura de código y tiene una complejidad técnica alta.



[Scikit Fairness](#): Ofrece herramientas para **cada etapa del pipeline de datos: datos, preprocesamiento, modelo, post-procesamiento y métricas**. Requiere escribir bastante código. Curva de aprendizaje alta.


Algunos frameworks para python:




[What-if tool](#): Orientado a **métricas de fairness**, exploración de datos tabulares y **contrafácticos**. Tiene soporte para imágenes y texto. UI interactiva, no hace falta escribir código.

Fairlearn


[Fairlearn](#): Métricas de **fairness**. Recursos educativos y buena documentación y tiene una complejidad



[Scikit Fairness](#): Ofrece herramientas para **datos, preprocesamiento, y métricas**. Requiere escribir bastante código. Cur



Algunos frameworks para python:



[Shap-index/values](#): Orientado a **explicabilidad**. Los valores Shapley son un concepto del campo de teoría de juegos cooperativos cuyo objetivo es medir la contribución de cada jugador en el juego. Requiere escribir código.



[Alibi](#): Orientado a **explicabilidad**, incluye técnicas para **imágenes** y **texto**. Requiere escribir código.



[AllenNLP](#): Orientado a **explicabilidad de modelos de NLP**. Complejidad técnica alta. Requiere mucho expertise en NLP, pero está bien documentado. Requiere escribir código.



[LIT \(Language Interpretability Tool\)](#): Orientado a explicabilidad de **modelos de NLP**. Complejidad técnica baja. Puede usarse a distintos niveles de profundidad técnica. Muy adaptable a casi cualquier tipo de modelo de texto. Buena documentación y soporte activo, sigue en desarrollo activo. Desarrollado por Google

Algunos frameworks para python:



[Presidio](#): Orientado a **anonimización de datos**. Provee analíticas y anonimización para textos sensible como números de tarjetas de crédito, nombres, lugares, números de seguridad social, billeteras de bitcoins, números de teléfono de EEUU y datos financieros.



[Aequitas](#): toolkit para **auditar modelos de AA** orientado a desarrolladores, analistas, organizaciones gubernamentales y entes legislativos.

[Yellowbrick](#): Orientado a **visualización** de varias métricas de evaluación de clusters. Minimiza escritura de código comparado a otras herramientas de visualización.

Conclusión

Los frameworks nos dan libertad para realizar mucho análisis sin escribir código.

Nos permiten formular hipótesis y descartarlas rápidamente.

El análisis debe adaptarse a los distintos casos de uso de nuestras aplicaciones

Es fácil perderse en el análisis y no tener conclusiones claras

Inspección sencilla de los datos



¿Podría ser utilizado por personas no técnicas?

A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines. The nodes are represented by small circles, some of which are larger and have concentric circles inside, suggesting a hierarchical or multi-layered structure. The lines are thin and gray, connecting the nodes in a non-linear fashion.

More on privacy

Trends in Language Modeling

- Large language models are very good at generating text and learning representations. However:
 - They are extremely large models: high capacity for memorization
 - They are trained on huge, unvetted, scraped data: high potential for harmful/hateful/private content



Large Models are Leaky!



WHEN YOU TRAIN PREDICTIVE MODELS ON INPUT FROM YOUR USERS, IT CAN LEAK INFORMATION IN UNEXPECTED WAYS.

What does preserving privacy in language modeling require?

- To claim a language model is privacy preserving, it must only reveal private information (aka “secrets”) in the right contexts and to the right people. We have to define the following:

in what contexts a secret can be shared without violating privacy?

what information is contained in the secret?

which people know the secret (the "in-group")?

- Hard to identify on scraped/collected data

Challenges in Identifying Context

- Privacy is not a 0-1 thing, it's a spectrum
 - A phone number could be private in one context, public in another
 - Subject, sender, recipient, information type all determine the context

Challenges in Identifying Secrets

Form and Meaning: There are many ways to communicate any piece of information.

Repeated information can still be private information.

Language evolves, and so does private information.

Privacy Expectations: What Are We Doing Now?



Scrubbing:

- Removal of Personally Identifiable Information (PII)
- Challenges: Limited to well-defined secrets, hard to keep up with language evolution

Differential Privacy:

- Designed to assure users that contributing their data to a dataset will not reveal much additional information about the use
- Challenges: Requires a unified definition for secret boundaries, which is very hard if not impossible to achieve for language data

What Can We Do?

- Publicly accessible data?
 - No, publicly accessible data is not public-intended: leaked messages, deleted texts, personal blogs
- Can users provide informed consent?
 - Mostly not . **If such a consent mechanism were to exist, it would be challenging for users to reach an informed decision about the consequences of their actions.**

What Can We Do?


- Train on publicly intended data
 - Such as books, articles, news
- Finetune locally on user-contributed data if needed
 - As long as the personalized models/parameters are not shared with others, the private data remains protected

- Privacy Preserving Methods

AI Belongs to Everyone

- ⦿ Despite what you may read in the news, there is much more **diversity** in AI research than just generative AI and chatbots
- ⦿ Many of the less visible applications are also making AI more **accessible** and **equitable** for different communities
- ⦿ These efforts are not only interesting from a research perspective, but they can also enable AI systems to reach their **full potential**

Costs of Generative AI



Thanks!

- Sasha Luccioni
- Laura Alonso Alemany
- Min Yen Khan, Yulia Tsvetkov and Karen Fört
- Fatemeh Miresghallah
- Sunipa Dev, Vinod Prabhakaran
- Jorge Sanchez, and my students
- Patrick Blackburn