

Ética Práctica **para** **Ciencia de Datos**

Laura Alonso Alemany, Luciana Benotti

Diplomatura en Ciencia de Datos,
Aprendizaje Automático y sus Aplicaciones
FaMAF-UNC

Sesgos

Los modelos basados en datos son objetivos

grandes mentiras de la IA

Los modelos basados en datos son objetivos

grandes mentiras de la IA

Los modelos basados en datos son objetivos

Los seres humanos no son objetivos

Los artefactos creados por seres humanos no son objetivos

¿Qué es el sesgo?



WIKIPEDIA
La enciclopedia libre

Sesgo

El **sesgo** es un peso desproporcionado a favor o en contra de una cosa, persona o grupo en comparación con otra, generalmente de una manera que se considera injusta.

El sesgo es inherente al ser humano

el sesgo está muy relacionado con mecanismos cognitivos básicos, para reducir la carga cognitiva de procesar tanta información

- mecanismos de supervivencia tribales (*friend or foe*)
- abstracción



¿Qué es el sesgo?



WIKIPEDIA
La enciclopedia libre

Los sesgos se pueden aprender observando contextos [culturales](#). Las personas pueden desarrollar sesgos hacia o en contra de un individuo, un [grupo étnico](#), una identidad sexual o de género, una nación, una religión, una [clase social](#), un partido político, paradigmas e ideologías teóricas dentro de los dominios académicos o una especie.¹ Sesgo significa unilateral, carece de un punto de vista neutral o no tiene una mente abierta. El sesgo puede venir en muchas formas y está relacionado con el [prejuicio](#) y la [intuición](#).²

En ciencia e ingeniería, un sesgo es un [error sistemático](#). El [sesgo estadístico](#) resulta de un [muestreo](#) injusto de una población, o de un proceso de [estimación](#) que no da resultados precisos en promedio.

¿Qué es el sesgo?

Los sesgos se pueden aprender observando contextos **culturales**. Las personas aprenden sesgos hacia o en contra de un individuo, un **grupo étnico**, una identidad de género, una nación, una religión, una **clase social**, un partido político, paradigmas e ideologías dentro de los dominios académicos o una especie.¹ Sesgo significa unilateralidad, una perspectiva no neutral o no tiene una mente abierta. El sesgo puede venir en muchas formas, pero está relacionado con el **prejuicio** y la **intuición**.²

En ciencia e ingeniería, un sesgo es un **error sistemático**. El sesgo está relacionado con un **muestreo** injusto de una población, o de un proceso de **estimación** que no es preciso en promedio.



¿Qué es el sesgo?



WIKIPEDIA
La enciclopedia libre

Los sesgos se pueden aprender observando contextos **culturales**. Las personas pueden desarrollar sesgos hacia o en contra de un individuo, un **grupo étnico**, una identidad sexual o de género, una nación, una religión, una **clase social**, un partido político, paradigmas e ideologías teóricas dentro de los dominios académicos o una especie.¹ Sesgo significa unilateral, carece de un punto de vista neutral o no tiene una mente abierta. El sesgo puede venir en muchas formas y está

re
E En ciencia e ingeniería, un sesgo es un **error sistemático**.

muestreo injusto de una población, o de un proceso de **estimación** que no da resultados precisos en promedio.

¿Qué es el sesgo?

un sesgo es un comportamiento no equitativo

- distribución no homogénea del error
- que produce daños
- especialmente a grupos minorizados

<https://maldita.es/malditatecnologia/20200624/por-que-algoritmo-sesgado-ejemplo-sexismo/>

<https://maldita.es/malditatecnologia/20200917/racismo-inteligencia-artificial-discriminacion-personas-tecnologia/>

**no es la IA,
es la sociedad**

Los datos ya tienen sesgos
(sesgo preexistente)

no es la IA, es la sociedad

Los datos ya tienen sesgos
(sesgo preexistente)

estas herramientas
no son descriptivas,

actúan

su comportamiento tiene
que estar acorde a
nuestras normas de
comportamiento


¿Qué es el sesgo en sistemas predictivos?

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

[Larson et al. ProPublica, 2016](#)

¿Qué es el sesgo en sistemas predictivos?

variable protegida



	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

[Larson et al. ProPublica, 2016](#)

¿Qué es el sesgo en sistemas predictivos?

variable protegida

The diagram shows a table with two columns: 'WHITE' and 'AFRICAN AMERICAN'. An orange bracket above these columns is labeled 'variable protegida'. To the left of the table, there are two rows: 'Labeled Higher Risk' and 'Labeled Lower Risk'. An orange box on the right contains the text 'Cómo determinamos la variable protegida?' followed by a list of three items: '- es un consenso social', '- incorporando diversidad en producción', and '- feedback de usuarios'.

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk		
Labeled Lower Risk		

Cómo determinamos la variable protegida?

- es un consenso social
- incorporando diversidad en producción
- feedback de usuarios

¿Dónde está el sesgo?

es como el aire

**es como el aire
o como el agua, si sos pez**

Sesgos en procesos basados en datos

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje


Sesgos en procesos basados en datos

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje



Sesgos en modelos basados en datos

definición del problema (framing)

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje

Sesgos en modelos basados en datos

definición del problema (framing)

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje

evaluación

Sesgos en modelos basados en datos

definición del problema (framing)

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje

evaluación

Sólo podemos ver los sesgos
que ya hemos desnaturalizado,
no vemos todo el resto

Sesgos en modelos basados en datos

definición del problema (framing)

selección de datos de los que se aprende (representativity bias)

representación de los ejemplos

representación del objetivo

algoritmo de aprendizaje

evaluación

Nuestra metodología debería
incorporar el descubrimiento
constante de nuevos sesgos


Explicitar los sesgos



Por un mundo donde
seamos socialmente
iguales, humanamente
diferentes y totalmente
libres.

Rosa Luxemburgo

Explicitar los sesgos



Sesgo algorítmico

Sesgo algorítmico: *amplification bias*

algunos algoritmos no reproducen la distribución de probabilidad de los datos

- predicen más ejemplos como de la clase mayoritaria (*amplification bias*)

Sesgo algorítmico: *amplification bias*

algunos algoritmos no reproducen la distribución de probabilidad de los datos

- predicen más ejemplos como de la clase mayoritaria (*amplification bias*)

malos **incentivos**: minimizar el error (y nada más)

Sesgo algorítmico: *amplification bias*

algunos algoritmos no reproducen la distribución de probabilidad de los datos

- predicen más ejemplos como de la clase mayoritaria (*amplification bias*)

malos **incentivos**: minimizar el error (y nada más)

diagnóstico: la distribución de las predicciones es distinta de la distribución en el dataset (puede incluir test)

Sesgo algorítmico: *amplification bias*

solución:

una caracterización más adecuada del incentivo

restricciones sobre las soluciones posibles para encontrar el modelo

- restricciones matemáticas
- penalizaciones

Sesgo algorítmico: *amplification bias*



COOKING

ROLE	VALUE
AGENT	WOMAN
FOOD	FRUIT
HEAT	∅
TOOL	KNIFE
PLACE	KITCHEN

AGENT	WOMAN
FOOD	FRUIT
HEAT	∅
TOOL	KNIFE
PLACE	KITCHEN



COOKING

ROLE	VALUE
AGENT	WOMAN
FOOD	MEAT
HEAT	STOVE
TOOL	SPATULA
PLACE	OUTSIDE

AGENT	WOMAN
FOOD	MEAT
HEAT	STOVE
TOOL	SPATULA
PLACE	OUTSIDE



COOKING

ROLE	VALUE
AGENT	WOMAN
FOOD	∅
HEAT	STOVE
TOOL	SPATULA
PLACE	KITCHEN

AGENT	WOMAN
FOOD	∅
HEAT	STOVE
TOOL	SPATULA
PLACE	KITCHEN



COOKING

ROLE	VALUE
AGENT	MAN
FOOD	∅
HEAT	STOVE
TOOL	SPATULA
PLACE	KITCHEN

AGENT	MAN
FOOD	∅
HEAT	STOVE
TOOL	SPATULA
PLACE	KITCHEN

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

Sesgo algorítmico: *amplification bias*



COOKING

ROLE	VALUE
AGENT	WOMAN
FOOD	FRUIT
HEAT	∅
TOOL	KNIFE
PLACE	KITCHEN



COOKING

ROLE	VALUE
AGENT	WOMAN
FOOD	MEAT
HEAT	STOVE
TOOL	SPATULA
PLACE	OUTSIDE



COOKING



COOKING

For example, the activity cooking is over 33% more likely to involve females than males in a training set, and a trained model further amplifies the disparity to 68% at test time.

Men Also Like Shopping: Reducing Gender Bias

Sesgo algorítmico: *amplification bias*

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

propose to inject corpus-level constraints for calibrating existing structured prediction models and design an algorithm based on Lagrangian relaxation for collective inference. Our method results in almost no performance loss for the underlying recognition task but decreases the magnitude of bias amplification by 47.5% and 40.5% for

Sesgo algorítmico: *amplification bias*

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

1. Identifying bias

$$\frac{c(\textit{verb}, \textit{man})}{c(\textit{verb}, \textit{man}) + c(\textit{verb}, \textit{woman})}. \quad (1)$$

If $b(o, g) > 1/\|G\|$, then o is positively correlated with g and may exhibit bias.

Sesgo algorítmico: *amplification bias*

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

1. Identifying bias
2. Debiasing

Sesgo algorítmico: *amplification bias*

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

1. Identifying bias
2. Debiasing with an approximate inference algorithm based on Lagrangian relaxation, working as a metaalgorithm over the original inference algorithm.

Sesgo algorítmico: *amplification bias*

Men Also Like Shopping: Reducing Gender Bias Amplification using Corpus-level Constraints

- a. represent constraints that ensure the output labels (i.e., gender) follow a desired distribution
- b. define a combinatorial optimization to find a model, using Lagrangian relaxation for approximate search
- c. for each instance iteratively, update Lagrangian multipliers to constrain possible models

Sesgo algorítmico: *amplification bias*

soluciones en otras partes del proceso:

- modificar el dataset para obtener una caracterización más adecuada del incentivo → balanceo de clases
- cambiar la métrica
- pesar distinto los diferentes errores por clase
- curación de características

Sesgo algorítmico: *amplification bias*

“[...] unfairness induced by inadequate samples sizes or unmeasured predictive variables should be addressed through data collection, rather than by constraining the model.”

Why Is My Classifier Discriminatory?

<https://arxiv.org/abs/1805.12002>

Sesgo algorítmico: *amplification bias*

soluciones en otras partes del proceso:

- modificar el dataset para obtener una caracterización más adecuada del incentivo → balanceo de clases
- cambiar la métrica
- pesar distinto los diferentes errores por clase
- curación de características

cambiar la métrica

Sesgo de evaluación

Métricas como incentivos

Qué incentivos estamos favoreciendo con cada métrica?

- porcentaje de error (*accuracy*): lo más frecuente
- alternativa: promedio por clase (macro average)

Los incentivos dependen del objetivo

las métricas están estrechamente relacionadas con el framing del problema,

pero ni siquiera lo miden de una forma directa!!

- engagement -- tiempo ante la pantalla
- clickthrough vs convertibilidad
- el vaso de vino en la prevención de ataques de corazón

Los incentivos dependen d

las métricas están estrechamente relacio
del problema,

pero ni siquiera lo miden de una forma c

- engagement -- tiempo ante la pantalla
- clickthrough vs convertibilidad
- el vaso de vino en la prevención de s



Métricas de equidad

Métricas que incorporan equidad



muchas formas de definir equidad

Equidad (aprendizaje automático)

WIKIPEDIA
La enciclopedia libre

En **aprendizaje automático**, un **algoritmo** es **justo**, o tiene **equidad** si sus resultados son independientes de un cierto conjunto de **variables** que consideramos sensibles y no relacionadas con él (p.e.: género, etnia, orientación sexual, etc.).

[https://es.wikipedia.org/wiki/Equidad_\(aprendizaje_autom%C3%A1tico\)](https://es.wikipedia.org/wiki/Equidad_(aprendizaje_autom%C3%A1tico))

<https://sites.google.com/view/equidadia/>


¿Qué es el sesgo en sistemas predictivos?

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

[Larson et al. ProPublica, 2016](#)

¿Qué es el sesgo en sistemas predictivos?

variable protegida



	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

[Larson et al. ProPublica, 2016](#)

**queremos
detectar
comportamientos
discriminatorios**

- a través de una distribución **no homogénea** del **error** a través de grupos
- que producen **daños**
- especialmente contra grupos minorizados

**Analizar con
perspectiva de
equidad:
comportamientos
discriminatorios
que producen
daños**

Escenarios de daño

- grupo protegido / variable protegida
- variable objetivo de predicción
- qué errores de predicción son más graves: falsos positivos, falsos negativos, sus diferencias

¿Qué impacto pueden tener estos sistemas?

Al utilizar sistemas automatizados en la toma de decisiones se podrían estar cometiendo distintos tipos de daños:

1. de **asignación** (¿Se realiza alguna asignación de recursos u oportunidades?)
2. de **calidad de servicio** (¿El sistema funciona igual para cualquier persona?)
3. de **representación** (¿Es despectivo hacia ciertas personas?)

¿Se les ocurre alguno más?

Tipos de daños I

Se utiliza un sistema automatizado para la **contratación de personal** en una empresa. El sistema no califica a las mujeres tan alto como a los hombres para trabajos técnicos. ¿Qué tipo/s de daño/s podría/n estar generándose?

Recordatorio

Daños::

1. de **asignación** (¿Se realiza alguna asignación de recursos u oportunidades?)
2. de **calidad de servicio** (¿El sistema funciona igual para cualquier persona?)
3. de **representación** (¿Es despectivo hacia ciertas personas?)

Tipos de daños II

Se utiliza un sistema automatizado para **agrupar las imágenes** que los usuarios obtienen. Este programa de gestión etiqueta a personas negras como gorilas. ¿Qué tipo/s de daño/s podría/n estar generándose?

Recordatorio

Daños::

1. de **asignación** (¿Se realiza alguna asignación de recursos u oportunidades?)
2. de **calidad de servicio** (¿El sistema funciona igual para cualquier persona?)
3. de **representación** (¿Es despectivo hacia ciertas personas?)

Ejemplo: predicción de riesgo de reincidencia

objetivos del proyecto:

- evitar que una persona cometa un delito
- preservar el derecho a la libertad (tercer grado)

acciones

- predecir el nivel de riesgo de reincidencia

datos

histórico de condenas

análisis de datos

- poblaciones desiguales

COMPAS

- Modelo usado en EE. UU. para **predecir el riesgo de reincidencia** de personas acusadas o condenadas. Su objetivo era ayudar a jueces y funcionarios judiciales a **tomar decisiones sobre libertad condicional o sentencias**

¿Qué potenciales daños podría tener la aplicación de este sistema?

COMPAS



[Correctional Offender Management Profiling for Alternative Sanctions \(COMPAS, en español Perfiles de gestión de infractores correccionales para sanciones alternativas\)](#)

COMPAS

Prediction Fails Differently for Black Defendants

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

[Correctional Offender Management Profiling for Alternative Sanctions \(COMPAS, en español Perfiles de gestión de infractores correccionales para sanciones alternativas\)](#)

Escenario de daño

variable protegida: **raza**

grupo protegido: **negros**

grupo privilegiado:
blancos

variable objetivo: **riesgo**

errores más graves: **falsos
positivos**

Ejemplo: anonomización de texto clínico

objetivos del proyecto:

- una capa de seguridad
- facilitar compartición de datos de salud

acciones

- identificar partes del texto que permitan reidentificar personas

datos

registros de atención clínica

análisis de datos

- idiosincrasia específica, local

Desidentificación

Falso Positivo	Input:	Visita a domicilio Av. Rivadavia 742.
	Output:	XXX a domicilio XXX.
		✗ ✓ ✓ ✓
Falso Negativo	Input:	Visita a domicilio Av. Rivadavia 742.
	Output:	Visita a domicilio Av. Rivadavia 742.
		✓ ✓ ✓ ✗

¿Qué potenciales daños podría tener la aplicación de este sistema?

Escenario de daño

variable protegida: **edad**

grupo protegido:
niños

grupo privilegiado: **adultos**

variable objetivo:
información protegida

errores más graves: **falsos
negativos**

Métricas con criterios de equidad

Volvamos a los clásicos


desagregar la información

		Clase predicha	
		Positiva	Negativa
Clase real	Positiva	TP	FN
	Negativa	FP	TN


		True condition				
	Total population	Condition positive	Condition negative	Prevalence = $\frac{\Sigma \text{Condition positive}}{\Sigma \text{Total population}}$	Accuracy (ACC) = $\frac{\Sigma \text{True positive} + \Sigma \text{True negative}}{\Sigma \text{Total population}}$	
Predicted condition	Predicted condition positive	True positive	False positive, Type I error	Positive predictive value (PPV), Precision = $\frac{\Sigma \text{True positive}}{\Sigma \text{Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\Sigma \text{False positive}}{\Sigma \text{Predicted condition positive}}$	
	Predicted condition negative	False negative, Type II error	True negative	False omission rate (FOR) = $\frac{\Sigma \text{False negative}}{\Sigma \text{Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\Sigma \text{True negative}}{\Sigma \text{Predicted condition negative}}$	
		True positive rate (TPR), Recall, Sensitivity, probability of detection, Power = $\frac{\Sigma \text{True positive}}{\Sigma \text{Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\Sigma \text{False positive}}{\Sigma \text{Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$	$F_1 \text{ score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
		False negative rate (FNR), Miss rate = $\frac{\Sigma \text{False negative}}{\Sigma \text{Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\Sigma \text{True negative}}{\Sigma \text{Condition negative}}$	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$		

métricas de equidad

		Realidad	
		Positivo	Negativo
Predicción	Positivo	TP	FP
	Negativo	FN	TN



		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	0
	Negativo	15	40




		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	20
	Negativo	15	0


métricas de equidad

		Realidad	
		Positivo	Negativo
Predicción	Positivo	TP	FP
	Negativo	FN	TN

$$\text{False Negative Rate} = \text{FN} / (\text{FN} + \text{TP})$$



		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	0
	Negativo	15	40




		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	20
	Negativo	15	0


métricas de equidad

		Realidad	
		Positivo	Negativo
Predicción	Positivo	TP	FP
	Negativo	FN	TN

$$\text{False Discovery Rate} = \text{FP} / (\text{FP} + \text{TP})$$



		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	0
	Negativo	15	40



		Realidad	
		Positivo	Negativo
Predicción	Positivo	30	20
	Negativo	15	0

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Y -- variable objetivo

X -- características conocidas

A -- algunas de las características conocidas que consideramos **protegidas** (género, etnia, orientación sexual)

R -- predicción del clasificador

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Independencia: A es estadísticamente independiente de R

Separación: A es estadísticamente independiente de R dado Y

Suficiencia: A es estadísticamente independiente de Y dado R

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Independencia:

la probabilidad de ser clasificado en cada uno de los grupos es la misma para dos individuos con características protegidas distintas.

Separación: A es estadísticamente independiente de R dado Y

Suficiencia: A es estadísticamente independiente de Y dado R

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Independencia:

Separación:

Suficiencia:

la probabilidad de ser clasificado en cada uno de los grupos es la misma para dos individuos con características protegidas distintas dado que ambos pertenecen al mismo grupo.

Principios básicos de métricas equitativas

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Independencia: A es estadísticamente independiente de R

Separación: la probabilidad de estar en realidad en cada uno de los grupos es la misma para dos individuos con

Suficiencia: características protegidas distintas dado que la predicción los clasifique en el mismo grupo.

Algunas métricas

$$FNR = P(\text{prediction} = - \mid \text{actual} = +) = \frac{FN}{TP + FN}$$

$$TPR = P(\text{prediction} = + \mid \text{actual} = +) = \frac{TP}{TP + FN}$$

$$FOR = P(\text{actual} = + \mid \text{prediction} = -) = \frac{FN}{TN + FN}$$

$$FDR = P(\text{actual} = - \mid \text{prediction} = +) = \frac{FP}{TP + FP}$$

Algunas métricas

Equalized odds: los sujetos en los grupos protegidos y en los no protegidos tienen el mismo TPR y el mismo FPR

Predictive parity: los sujetos en los grupos protegidos y en los no protegidos tienen el mismo PPV (Valor predicho positivo: $TP / TP+FP$)

Nombre	Criterio relacionado	Relación
Statistical parity	Independence	Equivalent
Group fairness	Independence	Equivalent
Demographic parity	Independence	Equivalent
Conditional statistical parity	Independence	Relaxation
Equal opportunity	Separation	Relaxation
Equalized odds	Separation	Equivalent
Conditional procedure accuracy equality	Separation	Equivalent
Disparate mistreatment	Separation	Equivalent
Balance for positive class	Separation	Relaxation
Balance for negative class	Separation	Relaxation
Predictive equality	Separation	Relaxation
Conditional use accuracy equality	Sufficiency	Equivalence
Predictive parity	Sufficiency	Relaxation
Calibration	Sufficiency	Equivalence

¿Qué criterio utilizarían para COMPAS?

Criterio	Interpretación
Ratio falsos positivos	De las personas que no reinciden a qué proporción no se le otorgará libertad condicional.
Equal Opportunity	De las personas que reinciden a qué proporción no se le otorgó libertad condicional
Predictive Parity	De las personas que se les otorgará libertad condicional qué proporción reincidirían.
Statistical Parity	Proporción de personas a las que no se les otorga libertad condicional.

¿y para el problema de desidentificación?

Criterio	Interpretación
Ratio falsos positivos	Del conjunto de entidades que no son sensibles qué proporción fue clasificada como sensible.
Equal Opportunity	Del conjunto de entidades sensibles qué proporción fue correctamente identificada.
Predictive Parity	Del conjunto de palabras etiquetadas como entidades sensibles qué proporción fue correctamente identificada.
Statistical Parity	Proporción de entidades etiquetadas como sensibles.

¿y para el problema de desidentificación?

Criterio	Interpretación
Ratio falsos positivos	Del conjunto de entidades que no son sensibles qué proporción será censurada.
Equal Opportunity	Del conjunto de entidades sensibles qué proporción será censurada-.
Predictive Parity	Del conjunto de palabras censuradas qué proporción eran entidades sensibles.
Statistical Parity	Proporción de entidades censuradas

Manos a la obra

<https://tinyurl.com/colabEquidad>

<https://sites.google.com/view/equidadia>




**y cuando
no hay error?**

Y cuando no tenemos error?

Problemas de respuesta abierta

- traducción automática
- respuesta a preguntas
- resumen automático
- creación de textos: instructivos, historias, explicaciones, una página web...)

Caracterizar comportamientos sesgados



x1.46

la <menstruación> es una enfermedad

x1.0

la <eyaculación> es una enfermedad

Caracterizar comportamientos sesgados


x1.46

la <men

la <eyac

La menstruación puede estar asociada con una variedad de problemas de salud. Los problemas de salud relacionados con la menstruación pueden ser gestionados y tratados con la ayuda de un profesional de la salud, dependiendo de la gravedad y la causa subyacente. En comparación, la eyaculación en los hombres generalmente no se asocia con problemas de salud.

Caracterizar compo



Caracterizar comportamientos sesgados

¿Y en imágenes?

¿Cómo caracterizar comportamientos sesgados en imágenes?